WISE iRAG V2 Document Extractor

Administrator & Developer's Guide

Version 1.0

(주)와이즈넛 경기도 성남시 분당구 대왕판교로644번길 49 DTC타워 5,6층

Copyright © WISEnut. All Rights Reserved

문서 개정 이력

버전	변경 일자	변경 내용	작성자
1.0	2025-02-04	최초 작성	임병수
1.0	2025-02-07	설치, 문서 수집, 수집 문서 추출 내용 추가	박정훈

목차

1. 개요 **4**
1.1. 목적 4
1.2. 시스템 권장 요구사항 4
1.3. 서비스 관련 요구사항 4
1.4. 기능 5
2. 설치 **6**
2.1. 설치 6
2.1.1. Bridge 6
2.1.2. DocuExtract 10
2.1.3. PassageSelection 11
2.2. 실행 및 종료 13
3. 문서 수집 **15**
3.1. 수집 대상 15
3.2. 수집 결과 16
4. 수집 문서 추출 **17**
4.1. 문서 추출 17
4.2. 암/복호화 17
4.2.1 암호화 API 18
4.2.2 복호화 API 18
4.3. 문서 생성 19
5. 추출 문서 분할 **20**
5.1. 패턴 분할 방식 20
5.2. 토큰 분할 방식 20

1. 개요

1.1. 목적

본 문서 수집기는 iRAG에서 사용될 문서를 수집, 이를 검색 가능한 형태와 크기로 가공하여 RAG 서비스 운영에 필요한 정보 수집, 독립적 의미 단위의 분리를 통한 데이터 품질 향상을 목적으로 한다.

1.2. 시스템 권장 요구사항

종류	구분
OS	Ubuntu 16.04 LTS 이상 Red Hat Enterprise Linux (RHEL) 8 이상 Linux Centos 8 이상
Disk	여유공간 30GB 이상
CPU	2 Core 이상

1.3. 서비스 관련 요구사항

종류	구분
libreOffice	6.4 이상
GhostScript	9.25 이상

1.4. 기능

- 문서 수집
- 문서 변환 / 처리 / 암복호화 기능
- 데이터 분리 기능

2. 설치

2.1. 설치

2.1.1. Bridge

Bridge : 문서를 DB, WEB, File등에서 수집 이후 JSON형태의 정형화된 데이터로 변환해주는 모듈. 다양한 형태의 데이터로 부터 규격화된 JSON 형식의 데이터로 변환하여 이후 검색에 사용할 수 있게 한다.

파일 구성은 다음과 같다.

파일명	역할
batch/bridge.sh	Bridge 모듈을 실행하는 shell script
batch/setenv	Birdge 모듈을 실행하기 위한 환경 변수 설정 파일
bridge/..	Bridge 모듈에 필요한 부가, 설정 파일 등
bridge/bridge.jar	Bridge 모듈의 빌드 파일
config/source.xml	Bridge 모듈의 실행 설정 파일

Bridge 모듈을 실행하기 위한 설정 파일은 다음과 같다.

config/source.xml

```
<Source id="file" type="file" sourcealias="file" extension="json">
  <RefColl id="file" prefix=""/>
  <SCDdir path="resultpath"/>
  <Date format="none_time_t" order="4"/>
  <DocumentAi ip="127.0.0.1" port="8000" local="true"/>
  <CatalogInfo>
    <Mapping tagname="DOCID" colnum="0"/>
    <Mapping colnum="1" tagname="subject" type="filename" convert=""/>
    ...
    <Mapping colnum="6" tagname="alias" type="gubun" convert=""/>
```

```
    </CatalogInfo>
    <TargetFile path="/home/ubuntu/file-extract-test" depth="0" dir="exclude"/>
    <History path="/home/ubuntu/package/history/"/>
    <DirAcceptRule>
      <Allow rule="*"/>
    </DirAcceptRule>
    <FileAcceptRule>
      <Allow rule="*.docx"/>
      ...
      <Deny rule="*"/>
    </FileAcceptRule>
</Source>
```

주의
config 설정은 대소문자를 구분하고, XML 문법에 맞게 작성해야 한다.

[Source 설정]

속성 (Attribute)	값 (Value)	설명
id	문자열	수집 설정을 구분하는 값을 지정. Bridge를 실행할 때 사용하는 옵션인 srcid이기도 함.
type (옵션)	db web file	해당 Source가 데이터를 가져오는 목적지. DB, Web, file 설정 가능
sourcealias (옵션)	문자열	SCD 파일에 해당 source의 출처가 어디인지 구분하기 위해 sourcealias를 넣어 줄 때 사용.
extension (옵션)	json scd	수집된 파일 포맷을 JSON 또는 SCD로 설정한다. (default : json)
charset (옵션)	utf-8 euc-kr shift-jis euc-jp gb2312	SCD 파일을 구성하고 있는 문자 집합을 설정. 기본값은 utf-8이며 euc-kr, shift-jis와 같이 설정.

[Source.RefColl 설정]

속성 (Attribute)	값 (Value)	설명
id	문자열	해당 Source가 참조하는 Collection ID를 지정. 여러 개의 Source가 하나의 Collection을 참조할 수 있음.
prefix	문자열	Collection에 참조하는 Source가 여러 개일 경우 유일한 문서 구분 ID인 DOCID가 중복될 수 있음. 중복을 방지하기 위해서 #t#과 같은 문자를 사용.

[Source.SCDdir설정]

속성 (Attribute)	값 (Value)	설명
path	SCD 파일 디렉터리	결과 SCD 파일이 생성되는 디렉터리를 지정.

[Source.DocumentAi 설정]

속성 (Attribute)	값 (Value)	설명
ip	통신 ip	DocuExtract 모듈과 통신할 ip 주소
port	통신 port	DocuExtract 모듈과 통신할 port
local	true/ false	DocuExtract 모듈이 같은 서버에 있는지 유무
format	html/markdown	추출될 표 데이터의 데이터 타입, 기본값 html
ocr	true/false	문서내 존재하는 이미지 파일의 ocr 여부, 기본값 true

- docuExtract의 .env파일의 port 정보와 해당 port 정보는 같아야함

[Source. CategoInfo.Mapping설정]

속성 (Attribute)	값 (Value)	설명
colnum	0,1, …	SCD 항목의 index값을 나타냄.
fieldname	DOCID	SCD 항목의 이름을 지정.
alias(옵션)	y/n	alias="y"인 경우 *<Source sourcealias=" ">*로 설정한 값을 SCD의 해당 Field에 저장. 즉, 예를 들면 *<Source id = "news" sourcealias= "daily">*로 설정하였다면, 이 경우 'daily라는 값을 SCD의 alias필드에 저장..

type	File Bridge Data Type	▪ filename: File 문서의 이름. ▪ content : File 문서의 본문. ▪ fileext : File 문서의 확장자. ▪ fullpath : File 문서의 전체 경로. ▪ gubun : File 또는 디렉터리를 구분. ▪ dirpath : File 문서의 디렉터리 경로. ▪ filesize : File 문서의 크기. ▪ date : File 문서의 수정일. (YYYYMMDDhhmmss) ▪ modified date : File 문서의 수정일. (YYYY-MM-DD hh:mm:ss) ▪ extend : 확장 type으로 CatalogInfo에 Field 명이 필요한 경우에 지정. ▪ value : 임의의 값을 SCD파일에 저장할 때 지정
tagname		SCD 항목의 이름.
className (옵션)	Java Class	커스터마이징이 필요한 부분을 정의하여 사용하는 클래스를 className="kr.co.wisenut.common.filter.custom.Http2FilterData"과 같이 설정
convert (옵션)	문서의 charset 이름, 새로 저장 할 charset 이름	수집하는 Field의 Data 문자 집합을 변환할 수 있는 기능. 예) convert="8859_1,EUC-KR"으로 지정하였다면, 8859_1 Data를 EUC-KR로 문자 집합을 변경.

[Source.TargetFile 설정]

속성 (Attribute)	**값 (Value)**	**설명**
path depth dir	디렉터리	수집 대상 디렉터리 또는 파일의 PATH 값.

[Source.History설정]

속성 (Attribute)	**값 (Value)**	**설명**
path	디렉터리	수집한 파일의 이력 관리 파일의 PATH 값.

[Source.DirAcceptRule설정]

속성 (Attribute)	값 (Value)	설명
Deny/Allow	rule	디렉터리 PATH값으로 Allow와 Deny 규칙을 설정.

[Source. FileAcceptRule 설정]

속성 (Attribute)	값 (Value)	설명
Allow/ Deny	rule	Allow/Deny 값으로 수집/추출 가능 파일 확장자를 설정

2.1.2. DocuExtract

DocuExtract : Bridge에서 수집한 파일형태의 문서를 텍스트 기반의 데이터로 변환 해주는 모듈

파일 구성은 다음과 같다.

파일명	역할
bin/docuExtract/.env	모듈의 port, 암호화 key, 암호화 사전 위치, 로그 레벨의 설정 파일
bin/docuExtract/hwp5html	hwp5html라이브러리의 사용을 위한 별도 실행 파일
bin/docuExtract/hwp5proc	hwp5proc라이브러리의 사용을 위한 별도 실행 파일
bin/docuExtract/models/yolov10x_best.pt	이미지 OCR에서 사용할 YOLO 모델 파일
bin/docuExtract/dict/masking.xlsx	민감정보 암호화에 사용될 사전 파일
batch/installer_docuExtract.sh	필요 소프트웨어를 설치하는 쉘 스크립트
batch/docu_extract.sh	docuExtract 모듈의 실행/중지/재시작/상태확인을 위한 쉘 스크립트
bin/docuExtract/docuExtract	docuExtract 모듈의 빌드 파일

Docu Extract를 실행하기 전 installer_docuExtract.sh 파일을 실행하여 필수 소프트웨어를 설치한다.

installer_docuExtract.sh
docuExtract를 실행하기 위한 설정 파일은 다음과 같다.

.env : 모듈 실행을 위한 정보를 가지고 있는 파일

- PORT : docuExtract 모듈과 통신할 port 번호
- BASE_PATH : docuExtract디렉토리의 위치 정보
- ENCRYPT_KEY : 민감 정보에 대해 암/복호화를 진행할 암호화 key
- ENCRYPT_DICT : 암 / 복호화 사전의 경로
- LOG_LEVEL : 지정할 로그 레벨 값
- MODEL_PATH : YOLO 모델 파일의 위치
- LOG_PATH : 로그가 생성될 위치
- HWPBASE : hwp5html, hwp5proc 파일이 존재하는 디렉토리 위치 정보

** BASE_PATH는 docuExtract 디렉토리의 위치정보이며 상대 경로로 지정하는 경우 BASE_PATH와 LOG_PATH는 batch/docu_extract.sh를 기준으로 하여 상대경로를 설정한다.

docuExtract하위에 존재하는 암호화 사전 파일 및 YOLO 모델의 위치는 BASE_PATH에서 설정한 docuExtract 폴더의 위치를 기준으로 상대경로를 설정한다.

ex) BASE_PATH=/home/irag-package, MODEL_PATH=models/yolov10x_best.pt

-> 실제 모델 경로 : /home/irage-package/models/yolov10x_best.pt

2.1.3. PassageSelection

PassageSelection : Bridge에서 수집된 파일에서 추출/생성된 JSON파일을 독립적 의미가 있는 단위로 분리 해주는 모듈

파일 구성은 다음과 같다.

파일명	역할
config/passage-selection.yaml	분리 작업에서 사용될 설정 파일
bin/passageSelection/passageSelection	passageSelection 모듈의 빌드 파일
bin/passageSelection/.env	passageSelection 설정 파일
batch/passage_selection.sh	passageSelection 실행 스크립트

passageSelection을 실행하기 위한 설정 파일은 다음과 같다.

.env : 모듈 실행을 위한 정보를 가지고 있는 파일

- LOG_LEVEL : 지정할 로그 레벨 값

config.yaml은 데이터 분할 작업을 위한 설정 파일로 사용자가 직접 정의하여 사용할 수 있는 기능을 제공한다.

- pattern_separator : 패턴 분리 방식에서 사용할 패턴 정보입니다. 예를 들어, "제 1 조"와 같은 형식에서 숫자는 가변성이 있으므로, 패턴을 제 \d{1} 조로 설정합니다.
- max_token_size : 지정한 토큰(token)의 최대 크기 값입니다. 이 값에 따라 분할 작업이 진행됩니다.
- sentence_separator : 데이터에서 문장을 분리할 기호를 지정합니다. 여러 기호를 동시에 사용할 수 있습니다. 값이 지정되지 않으면, 내부 라이브러리에 기반한 기본 문장 분리 방식이 사용됩니다.

  분리된 문장은 사용자 지정 방식에 따라 다르게 처리되며, overlap_size에 의해 앞뒤로 겹쳐질 문장에 사용됩니다. 기존 문장별 분리가 아닌 별도의 사용자 지정 방식으로 분리하고 싶을 때 이 항목을 사용합니다.
- overlap_size : 분할된 데이터가 앞뒤로 겹치는 크기를 설정하는 값입니다.

이 값은 분할된 문장의 개수로, 몇 개의 문장이 앞뒤의 데이터와 중복으로 존재할지를 지정합니다.

2.2. 실행 및 종료

Bridge : source.xml의 설정값에 기반하여 수집 대상 및 mode에 기반하여 실행한다.

./bridge.sh <source.xml> <bridge-type> <source-id> <mode> [option]

- source.xml : source.xml의 경로
- bridge-type : 수집할 대상 (db, web, file)
- source-id : source.xml에서 설정한 source 태그의 id 값
- mode : 사용할 모드
- option : 추가 설정할 옵션 값

docuExtract : docu_extract.sh 파일을 통해 실행 및 재시작을 한다.

./docu_extract.sh start : 모듈 시작

./docu_extract.sh stop : 모듈 종료

./docu_extract.sh restart : 모듈 재시작

./docu_extract.sh status : 모듈 상태 확인

passageSelection : passage_selection.sh 파일을 통해 실행 한다.

./passage_selection.sh directoryPath config.yaml_path method

directoryPath : Bridge에서 생성한 JSON파일이 들어있는 디렉토리 주소

config.yaml_path : config.yaml의 경로

method : 작업을 진행할 방식 , 패턴 기반의 분리 방식과 token 크기의 분리 방식 존재 각각 pattern, token으로 사용

/{irag-home}/collection/{collection}/json/{index} 디렉토리 하위의 파일 분할 결과는 /{irag-home}/collection/{collection}/passage-selection/{index} 하위에 같은 파일명으로 생성됩니다.

ex) /{irag-home}/collection/{collection}/passage-selection/{index}/파일이름.json

3. 문서 수집

Bridge 모듈을 통해 수집할 문서 확장자의 종류와 데이터베이스, 웹등 어디서로부터 문서를 수집할지를 정한다.

Bridge(수집기)에 대해 더 자세한 내용은 iRAG V2 Search Engine 매뉴얼 V1.0을 참고하시길 바랍니다.

3.1. 수집 대상

DB, WEB, File로 부터 데이터를 수집한다.

- DB
- WEB
- file
    - MS-office
        - doc, docx
        - ppt, pptx
        - csv, xls, xlsx
    - 아래아 한글
        - hwp, hwpx
    - 이미지 파일
        - jpg, jpeg, png
    - 압축 파일
        - zip, tar
    - PDF

3.2. 수집 결과

bridge의 source.xml의 설정값에 따라 SCD/ JSON형식의 결과가 생성된다. 결과는 파일로 생성되며 각 고유한 DOCID로 구분되어 사용된다.

4. 수집 문서 추출

수집된 문서는 문서 추출 모듈(docuExtract)를 통해 기계가 이해할 수 있는 자연어로 변환하는 기능을 제공합니다. 다양한 문서 형식에서 데이터를 자동으로 추출하여 자연어로 변환합니다. 추출된 값은 다시 Bridge 모듈을 통해 파일별 DOCID를 갖는 JSON형식의 파일로 변환됩니다.

4.1. 문서 추출

파일 형태의 데이터에서 텍스트를 추출하여 Bridge에서 file 타입의 수집시 사용됩니다.
문서에서 추출할 대상은 문서 내 존재하는 문단, 표 , 이미지를 대상으로 데이터를 추출합니다.
추출된 표는 markdown 및 html 형식으로 추출합니다.
문서가 추출된 결과는 다음의 예시와 같습니다.

[파일제목.확장자] 추출된 문단 내용 <TABLE> 표 추출 정보 </TABLE> <IMAGE> 이미지 추출 정보 </IMAGE>

위 내용과 같이 파일 제목 및 추출한 문단 내용, 표 정보, 이미지의 추출 정보를 제공합니다. 표와 이미지의 경우 일반 문단에서 추출한 데이터와 다르게 태그 값을 추가하여 해당 정보의 출처를 확인 할 수 있도록 하는 기능을 지원합니다.

4.2. 암/복호화

추출된 문서 데이터 내부에 존재하는 개인 정보 및 민감한 데이터는 암/복호화 기능을 통해 외부에 노출 되지 않도록 암호화를 진행합니다. 암호화 사전을 통해 사용자에 의해 관리가 가능합니다. 또한 사용자가 원할 때 안전하게 원본 정보를 복원할 수 있습니다. 이를 통해 데이터 유출의 위험을 최소화 할 수 있는 기능을 제공합니다.

4.2.1 암호화 API

암호화기능은 추출된 문서 데이터에 존재하는 민감 데이터를 암호화가 필요할 시 암호화 된 데이터로 대체합니다.

URI	/chipher/encrypt
Method	POST
Content-Type	application/json

예시

URI	{ip}:{port}/chipher/encrypt
Body	{ "content": "주)와이즈넛은 "Perfect Communication"의 비전을 가지고 '사람과 사람', '사람과 사물', '사람과 세상'간자유롭게 평등한 의사소통을 할 수 있는 혁신적인 인공지능(AI)기술을 제공합니다.모든 사람이 모든 것들과 소통하는 세상, 그 중심에 와이즈넛이 있습니다." }
Response	"주)sxSfSfUkq+T/j3Z63K6LbQH7h9mju51EscRjEW0thteHh13aqCKLrfXz/9U=은 "Perfect Communication"의 비전을 가지고 '사람과 사람', '사람과 사물', '사람과 세상'간자유롭게 평등한 의사소통을 할 수 있는 혁신적인 인공지능(AI)기술을 제공합니다.\n모든 사람이 모든 것들과 소통하는 세상, 그 중심에 lqa1ew05rsRLfVymWCzYqRRod+GlCNe3FfD2Md7v1naRictXthz1yJHkcNY=이 있습니다."

4.2.2 복호화 API

복호화 기능은 암호화 데이터를 다시 원래 상태의 데이터로 복구 하여 원본 데이터를 제공합니다.

URI	/chipher/decrypt
Method	POST
Content-Type	application/json

예시

URI	{ip}:{port}/chipher/decrypt
Body	{ "content": "주)sxSfSfUkq+T/j3Z63K6LbQH7h9mju51EscRjEW0thteHh13aqCKLrfXz/9U=은 "Perfect Communication"의 비전을 가지고 '사람과 사람', '사람과 사물', '사람과 세상'간자유롭게 평등한 의사소통을 할 수 있는 혁신적인 인공지능(AI)기술을 제공합니다.\n모든 사람이 모든 것들과 소통하는 세상, 그 중심에 lqa1ew05rsRLfVymWCzYqRRod+GlCNe3FfD2Md7v1naRictXthz1yJHkcNY=이 있습니다." }
Response	"주)와이즈넛은 "Perfect Communication"의 비전을 가지고 '사람과 사람', '사람과 사물', '사람과 세상'간자유롭게 평등한 의사소통을 할 수 있는 혁신적인 인공지능(AI)기술을 제공합니다.\n모든 사람이 모든 것들과 소통하는 세상, 그 중심에 와이즈넛이 있습니다."

4.3. 문서 생성

추출된 자연어는 DOCID와 함께 JSON 형식으로 저장되어, 데이터의 구조화 및 관리가 용이합니다. 각 문서에 대한 DOCID를 통해 특정 문서와 관련된 정보를 쉽게 추적하고 관리할 수 있으며 특정 데이터를 신속하게 검색하는데 용이합니다.

본 모듈은 문서 수집부터 자연어 추출 및 JSON객체 변환, 파일로 저장하는 과정을 자동화하여 사용자는 수작업으로 데이터를 처리하는 데 소용되는 시간을 절약할 수 있습니다.

5. 추출 문서 분할

본 기능은 문서 내용을 효과적으로 구조화하는 것을 목적으로 하며, 정보 검색의 효율성 향상 및 리소스 절약을 위해 큰 JSON객체를 여러개의 객체로 나누는 작업을 지원합니다.
분할 대상인 데이터를 문장별로 분리 후 사용자가 지정한 방식으로 분할 작업을 진행합니다.
각 분할된 데이터가 앞뒤로 일정 부분 겹치도록 설정할 수 있는 기능을 제공하여 데이터의 연속성을 유지하고, 문맥을 보다 잘 이해 할 수 있도록 돕습니다.
자연어로 변환된 문서 데이터를 사용자가 지정한 단위로 분리하여 하위 DOCID를 갖는 여러 JSON 객체로 분할합니다.

5.1. 패턴 분할 방식

문단이나 챕터의 시작 부분에 나타나는 특정 패턴을 기준으로 데이터를 분리하는 기능입니다. 사용자가 정의한 특정 패턴 (예: “제 1 장”, “제 2절” 등)을 인식하여, 해당 패턴이 나타나는 지점을 기준으로 텍스트를 분할합니다. 이를 통해 각 챕터나 문단별 구분이 가능합니다.

5.2. 토큰 분할 방식

텍스트를 토큰(token) 크기에 따라 자동으로 구분하는 기능으로 분할 대상 데이터를 사용자가 설정한 특정 크기에 따라 텍스트를 자동으로 분할 합니다. 사용자는 원하는 토큰 크기를 자유롭게 설정할 수 있습니다.